Parte I - Atividades teóricas

Exercício 1

a) $P(A^C) = 1 - P(A) = 1 - \frac{1}{3} = \frac{2}{3}$

b) $P(A^C \cup B) = P(A^C) + P(B) - P(A^C B) = P(A^C) + P(B) - (P(B) - P(AB)) = P(A^C) + P(AB) = \frac{2}{3} + \frac{1}{6} = \frac{5}{6}$

c) $P(A \cup B^C) = P(A) + P(B^C) - P(AB^C) = P(B^C) + P(AB) = (1 - P(B)) + P(AB) = (1 - \frac{1}{4}) + \frac{1}{6} = \frac{5}{12}$

d) $P(AB^C) = P(A) + P(B^C) - P(A \cup B^C) = \frac{1}{3} + \frac{3}{4} - \frac{5}{12} = \frac{8}{12}$

e) $P(A^C \cup B^C) = 1 - P(AC) = 1 - 16 = \frac{5}{6}$

Exercício 2

a)

$$F_X(x) = P(X \leq x) = \int_{-\infty}^{x} f_X(\xi) d\xi = \int_{-\infty}^{x} \frac{1}{2} d\xi = \left[\frac{1}{2}\xi\right]_0^x = \frac{1}{2}x, \forall X \in [0, 2]$$

b) $E\{X\} = \int_{-\infty}^{\infty} x f_X(x) dx = \int_0^2 \frac{1}{2} x dx = \left[\frac{x^2}{4}\right]_0^2 = 1$

$E\{X^2\} = \int_{-\infty}^{\infty} x^2 f_X(x) dx = \int_0^2 \frac{1}{2} x^2 dx = \left[\frac{x^3}{6}\right]_0^2 = \frac{4}{3}$

$E\{X^3\} = \int_{-\infty}^{\infty} x^3 f_X(x) dx = \int_0^2 \frac{1}{2} x^3 dx = \left[\frac{x^4}{8}\right]_0^2 = 2$

Exercício 3

a) X_2, pois quanto mais próximo da distribuição uniforme, mais difícil é acertar o resultado de um evento aleatório "chutando um valor", ou seja, a variável aleatória X_2 carrega mais informação que a variável aleatória X_1, pois neste último eu poderia supor que o resultado será sempre 3 com uma taxa de acertos de 40% contra uma taxa de acertos de 25% para qualquer valor estimado para X_2 se não tivermos nenhuma informação *a priori*.

b) $H(X_1) = -\sum_x p(X_1) log_2[p(X_1)] = -[0,1(-3,32) + 0,2(-2,32) + 0,3(-1,74) + 0,4(-1,32)] = 1,85$

$H(X_2) = -\sum_x p(X_2) log_2[p(X_2)] = -[0,25(-2) + 0,25(-2) + 0,25(-2) + 0,25(-2)] = 2$

c) $D(P_1||P_2) = \sum_x p(X_1) log_2 \left[\frac{p(X_1)}{p(X_2)}\right] = 0,1(-1,32) + 0,2(-0,32) + 0,3(-0,26) + 0,4(-0,68) = -0,54$

$D(P_2||P_1) = \sum_x p(X_2) log_2 \left[\frac{p(X_2)}{p(X_1)}\right] = 0,25(1.32 + 0.32 - 0.26 - 0.68) = 0,18$

Exercício 4

a) $\mu_{ML} = argmax_\theta p(x|\mu) = argmax_\theta log[p(x|\mu)] = argmax_\theta \frac{p(x\mu)}{p(\mu)} = x$

b) $\mu_{ML} = argmax_\theta p(\mathbf{x}|\mu) = argax_\theta log[p(\mathbf{x}|\mu)] = argmax_\theta \sum_{k=1}^{N} log[p(x_K|\mu)] = argmax_\theta \sum_{k=1}^{N} log \left[\frac{p(x_K\mu)}{p(\mu)}\right]$

c)

Parte II - Atividade computacional

Solução fechada com MMQ

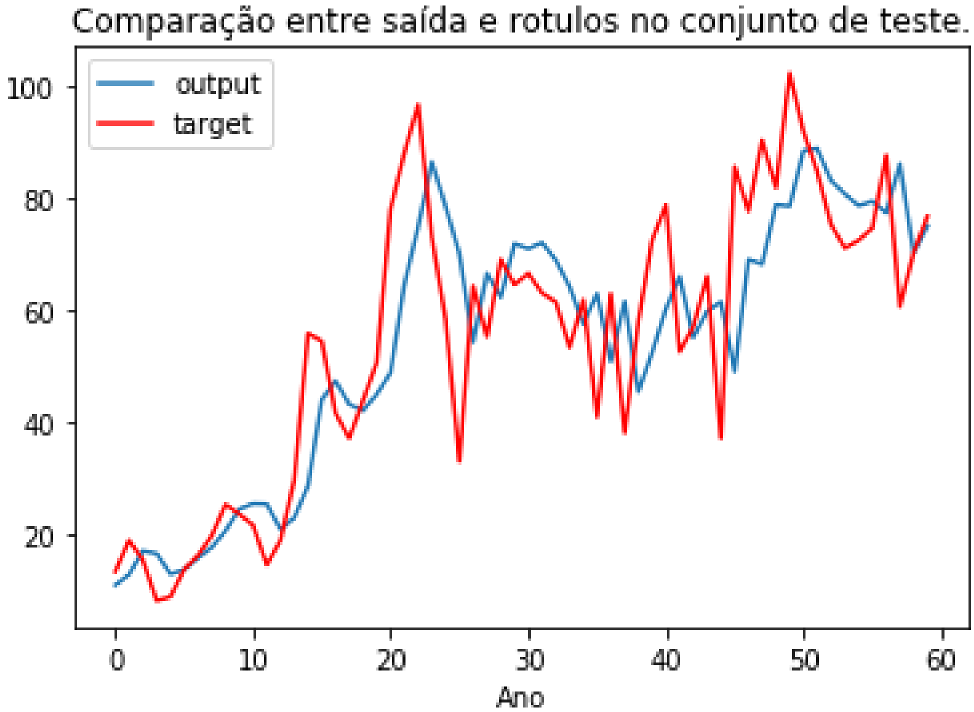

Figura 1: Saída prevista pelo modelo (azul) em comparação com valores reais dos últimos 5 anos (60 meses).

Solução com seleção de atributos pelo wrapper

Solução com seleção de atributos pelo filtro

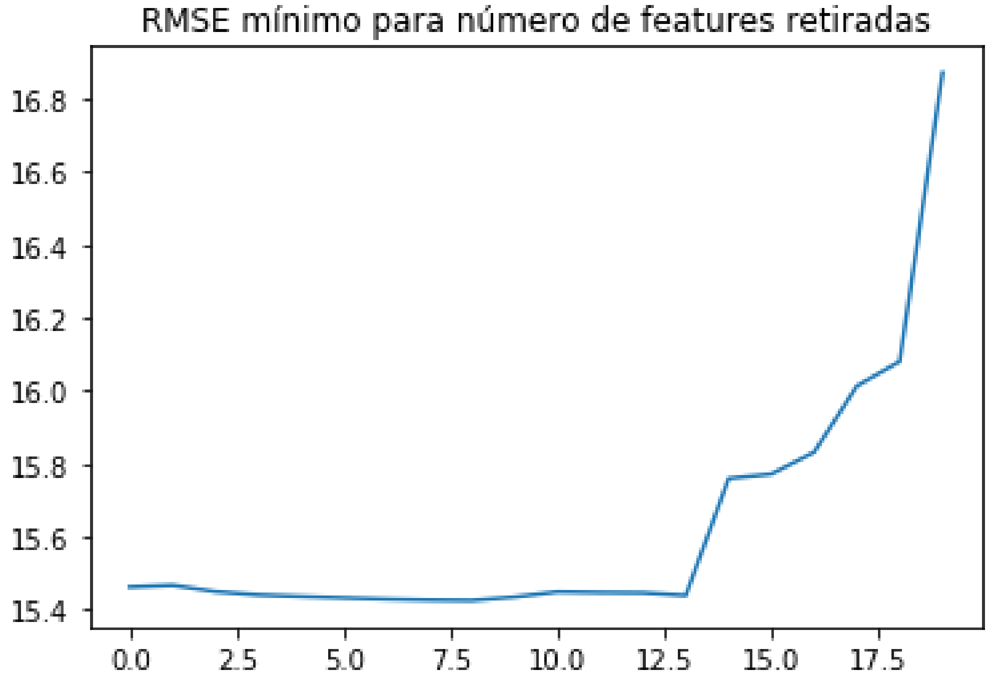

Figura 2: Menor RMSE para cada passo do wrapper (atributo retirado).

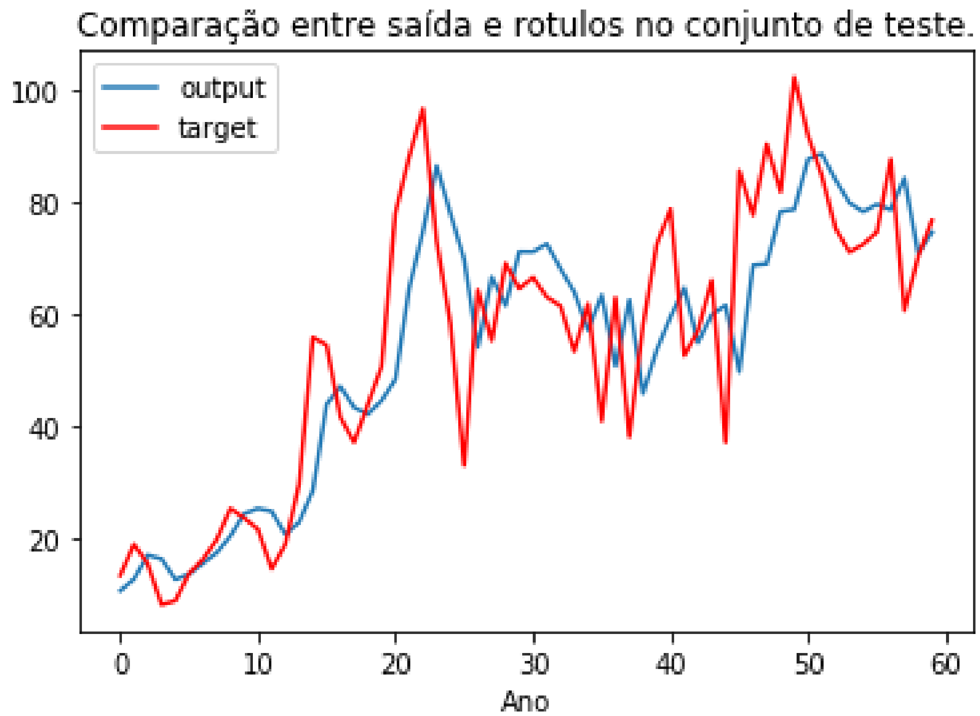

Figura 3: Saída prevista pelo modelo (azul) em comparação com valores reais dos últimos 5 anos (60 meses).

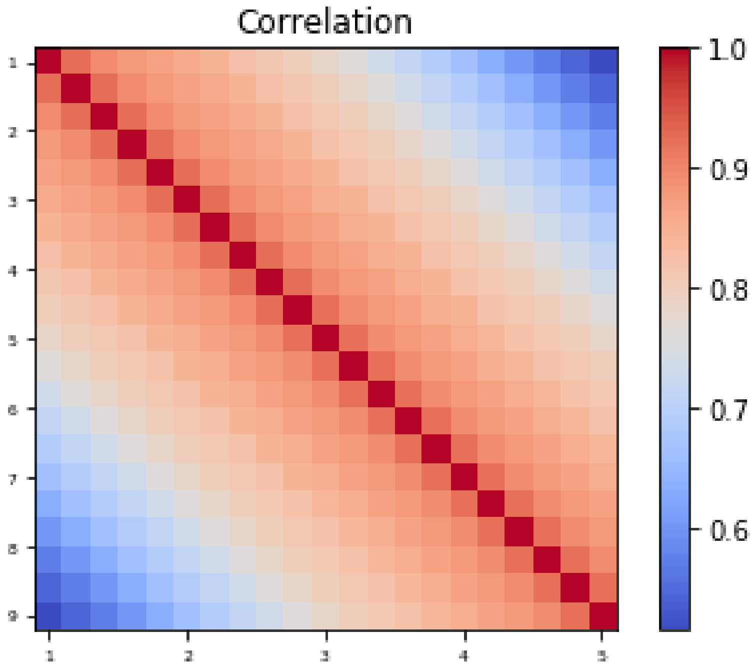

Figura 4: Saída prevista pelo modelo (azul) em comparação com valores reais dos últimos 5 anos (60 meses).

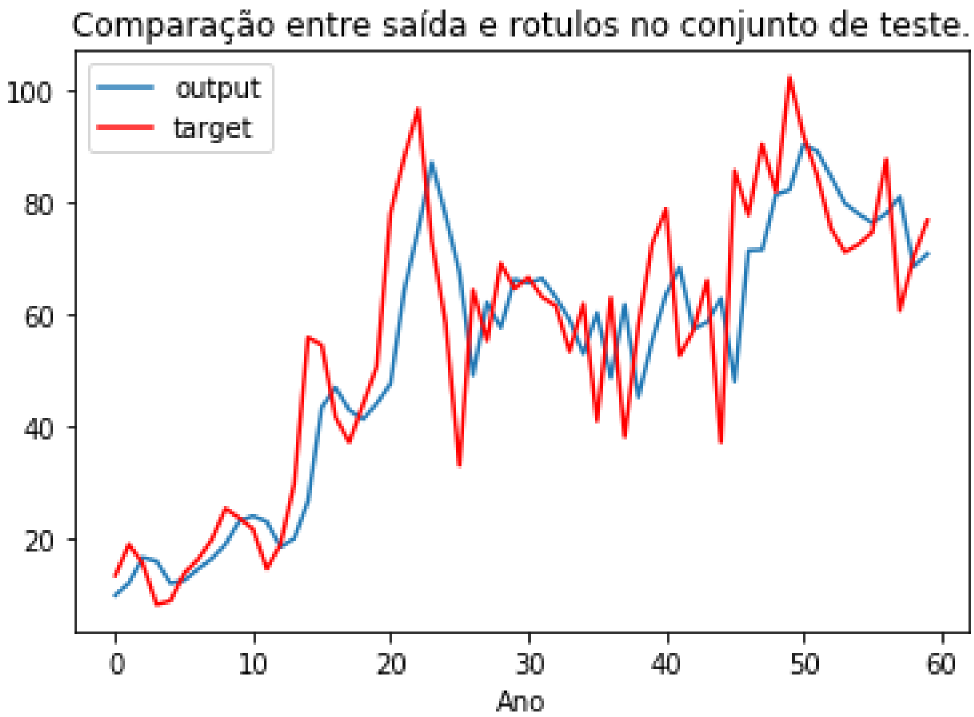

Figura 5: Saída prevista pelo modelo (azul) em comparação com valores reais dos últimos 5 anos (60 meses).

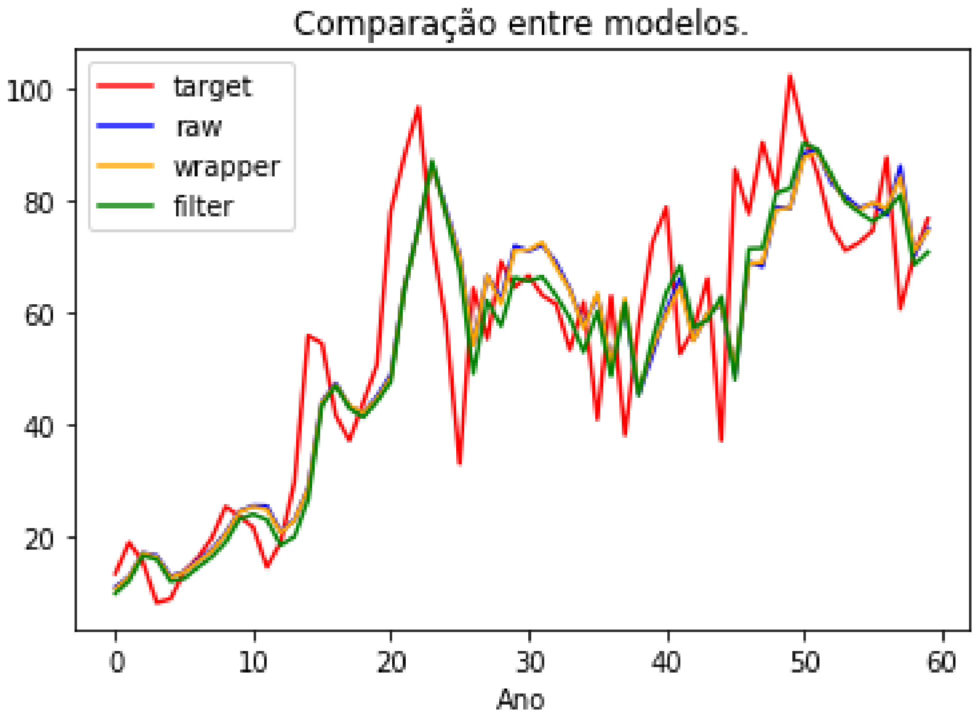

Figura 6: Saída prevista pelo modelo (azul) em comparação com valores reais dos últimos 5 anos (60 meses).